第六部分：多样性

1、推荐系统的多样性

相似性的度量

基于物品属性标签

根据类目、品牌、关键词等

（是由cv，nlp算法推断出来的）

可以根据一级类目、二级类目、品牌计算相似度

例子：

物品i：美妆、彩妆、香奈儿

物品j：美妆、香水、香奈儿

相似度：$sim_1(i,j)=1$，$sim_2(i,j)=0$，$sim_3(i,j)=1$

再根据类目、品牌、关键词等设置的权重，加权计算总的相似度

基于物品向量表征

用召回的双塔模型学到的物品向量（不好）

如采用内积，余弦相似度等方法

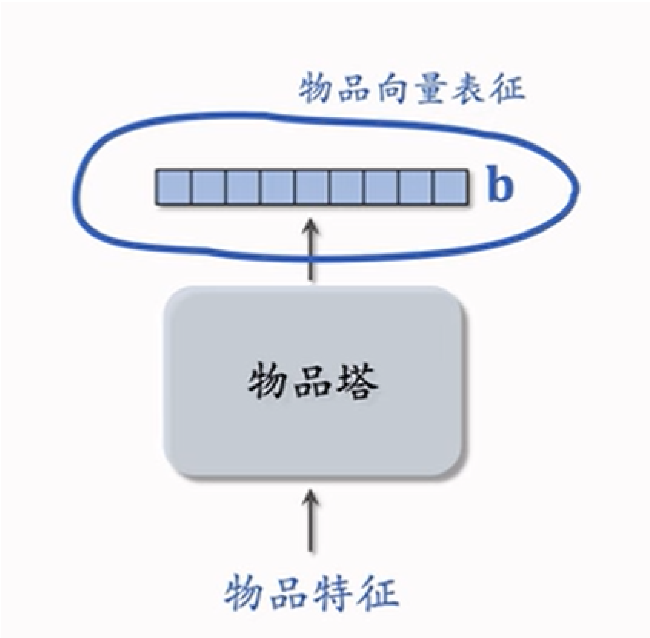

两个物品相似度高，则说明双塔模型得到的物品向量表征内积/余弦相似度高

但推荐系统头部现象很严重，新物品/长尾物品曝光和点击很少，双塔模型学不好这些物品的表征

基于内容的向量表征（好）

（根据cv，nlp模型提取出文字和图片的向量）

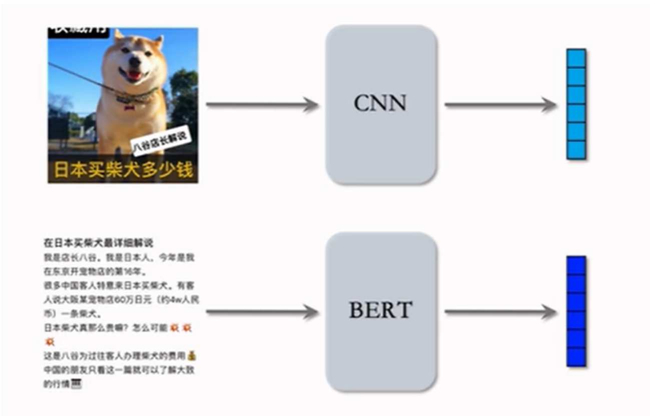

难点： 如何训练CNN、BERT

CLIP： 当前公认最有效的预训练方法

思想： 对于图片-文本二元组，预测图文是否匹配

优势： 无需人工标注，小红书的笔记天然包含图片+文字，大部分笔记图文相关

样本选取（和batch内负样本类似）：

正样本： 图片直接对应的文字

负样本： 如下图

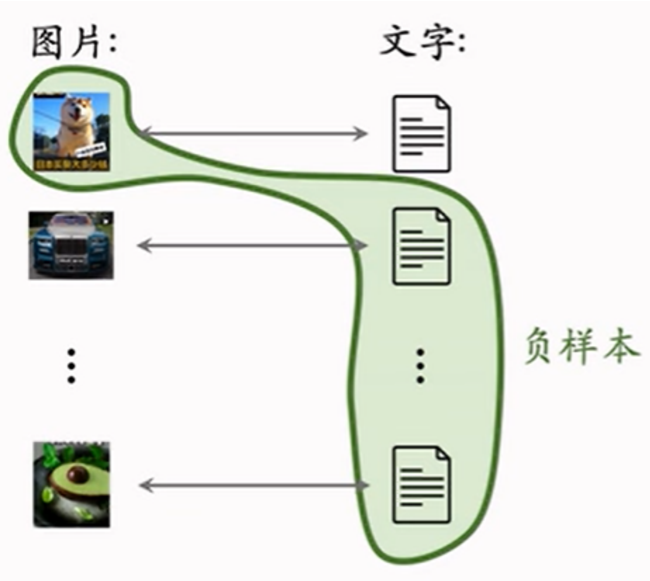

一个batch内有m对正样本，一张图片和m-1条文本组成负样本，那么这个batch内一共有m(m-1)对负样本

提升多样性的方法

考虑推荐系统的链路：

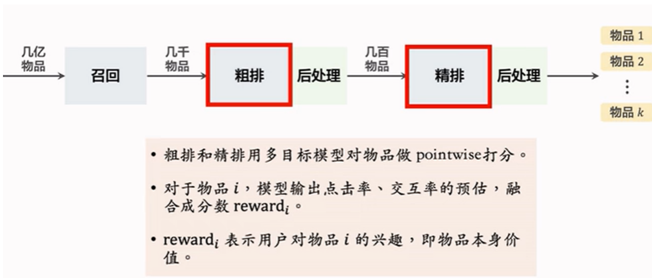

粗排和精排的分数用pointwise独立打分，不考虑物品之间的关联

然后对n个候选物品的打分进行排序，后处理就是从这n个候选物品（粗排n为几千，精排n为几百）选出k个，既要总分高，也需要它们有多样性

因此：

既要考虑n个候选物品的打分 $reward_1, reward_2, ..., reward_n$

也要考虑第i个物品和第j个物品的相似度sim（i,j）

精排的后处理：通常称为重排，它决定了哪k个物品被曝光，以及k个物品曝光的顺序

2、Maximal Marginal Relevance（MMR）

MMR先用在搜索排序，再用在推荐排序

MMR考虑的是物品间的相似度

MMR多样性算法

1、已选中的物品S初始化为空集，未选中的物品R初始化为全集{1,...,n}

2、选择精排分数$reward_i$最高的物品，从R移到S

当i和选中物品j相似度很高时，对物品i的选中起到抑制作用

θ参数用来平衡物品价值和相似度，θ越大，物品价值起作用越多，多样性起作用越少

最大MR：

• Maximal Marginal Relevance (MMR)：

$$\underset{i \in \mathcal{R}}{\mathrm{argmax}}\ \mathrm{MR}_i .$$

选出最大的MR作为MMR，对应物品i从R中移动到S

3、对2操作做k-1轮循环，结束后一共选出k个物品。由于每次循环S和R的集合情况都发生了变化，因此需要重新计算MR和MMR

滑动窗口的引入

上面MMR计算的问题

已选中的物品越多（集合S越大），越不容易找出R中的物品i，使得i与S中的物品都不相似——即max sim(i, j)总是约等于1，导致MMR算法失效

解决方案

设一个滑动窗口W，比如最近选中的10个物品，用W代替MMR公式中的S

（没有必要让第30个物品和第一个物品也具有很强的不相似，因此滑动窗口的方式是合理的）

重排的规则

1、最多连续出现k篇某种笔记

小红书推荐系统的物品分为图文笔记，视频笔记（以下数据仅用于举例，非真实）

最多连续出现k=5篇图文笔记，最多连续出现k=5篇视频笔记

例如，排i到i+4的全都是图文笔记，那么排在i+5的必须是视频笔记

2、每k篇笔记最多出现1篇某种笔记

运营推广笔记的精排分数会乘一个大于1的系数（boost），帮助笔记获得更多曝光

例如：为了防止boost影响体验，限制每k=9篇笔记最多出现1篇运营推广笔记

即：如果排在第i位的是运营推广笔记，那么排i+1到i+8的不能是运营推广笔记

3、前t篇笔记最多出现k篇某种笔记

排名前t篇笔记最容易被看到，对用户体验最重要（小红书的top4为首屏）

小红书推荐系统有带电商卡片的笔记，过多可能会影响体验

例如：

前t=1篇笔记最多出现k=0篇带电商卡片的笔记

前t=4篇笔记最多出现k=1篇带电商卡片的笔记

MMR+重排规则

重排结合MMR与规则，在满足规则的前提下最大化MR

具体做法：每一轮先用规则排除掉R中的部分物品（防止违反规则），得到子集 $\mathcal{R}'$，按下面规则计算（公式不变），即可符合要求：

$$\underset{i \in \mathcal{R}}{\operatorname{argmax}} \left\{ \theta \cdot \text{reward}_i - (1-\theta) \cdot \max_{j \in \mathcal{W}} \text{sim}(i,j) \right\}.$$

把 $\mathcal{R}$ 替换成子集 $\mathcal{R}'$

3、DPP（行列式点过程）

DPP的目标：从集合中选出多样的物品，它考虑选出的物品集合的多样性，是公认的最好的推荐系统多样性算法

DPP数学基础

二维空间

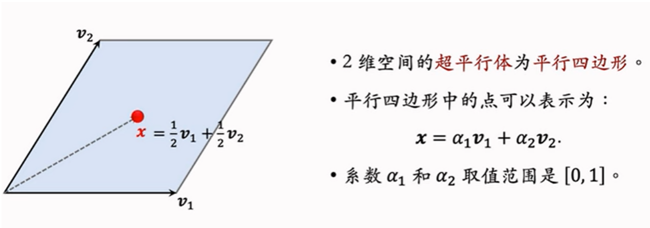

平行四边形的面积计算：采用底×高的方式计算面积，即以 v_1 为底，计算高 q_2；以 v_2 为底，计算高 q_1 也可

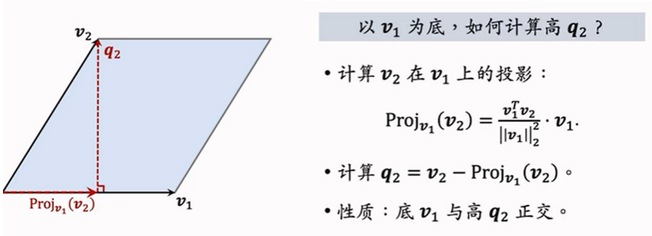

三维空间

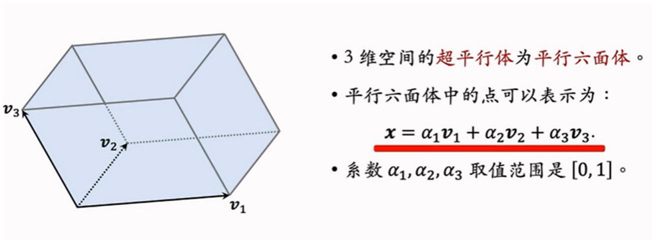

平行六面体的体积计算：采用底面积×高的方式计算面积，即计算平行四边形 $P(v_1, v_2)$的面积（它是平行六面体 $P(v_1, v_2, v_3)$的底），再乘以高 q_3（垂直于地面 $P(v_1, v_2)$）

问题：体积何时最大化，最小化?

设 v_1, v_2, v_3都是单位向量

当3个向量正交时，平行六面体为正方体，体积最大化，vol=1

当3个向量线性相关时，体积最小化，vol=0

多维空间

一组向量 $v_1, \ldots, v_k \in R^d$可以确定一个k维超平行体：

$P(v_1, ..., v_k) = [\alpha_1 v_1 + ... + \alpha_k v_k | 0 \le \alpha_1, ..., \alpha_k \le 1]$

要求k≤d，比如d=3维空间中可以有k=2维平行四边形，但不能有k=4维平行四边形

如果 $v_1, ... v_k$ 线性相关（即某个v可以用其它v表示），那么向量将落在一个平面上，则体积vol(P)=0

DPP算法衡量物品多样性

给定k个物品，把它们表征为单位向量 $v_1, ..., v_k \in R^d$，要求d≥k

用超平行体的体积衡量物品的多样性，体积介于0和1之间

如果 $v_1, ..., v_k$ 两两正交，此时体积将最大化，vol=1，说明物品之间多样性好

如果 $v_1, ..., v_k$ 线性相关，此时体积将最小化，vol=0，说明物品之间多样性差

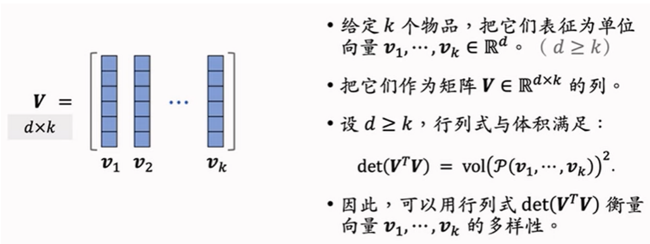

DPP多样性算法原理

精排给n个物品打分： $reward_1, ... reward_n$，其中n个物品的向量表征：$v_1, ..., v_n \in R^d$

从n个物品中选出k个物品，组成集合S，需要S：

价值大： 分数之和 $\Sigma_{j \in S} reward_j$ 越大越好

多样性好： S中k个向量组成的超平行体P(S)的体积越大越好

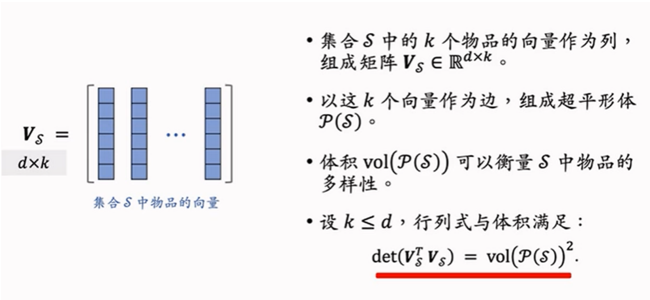

因此可以用**行列式**衡量向量（即物品）之间的多样性

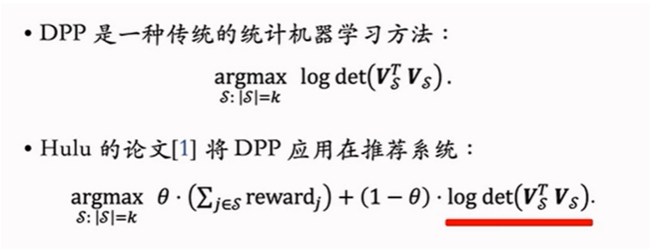

*论文的贡献在于**快速求解这个公式**

将上面公式 $V_S^T V_S$ 设为 $A_S(k \times k)$

设A为n×n矩阵，它的(i, j)元素为 $a_{ij} = v_i^T v_j$

给定向量 $v_1, \ldots, v_n \in R^d$，需要 $O(n^2 d)$时间计算A

$A_S = V_S^T V_S$为A的一个k×k子矩阵，如果 $i, j \in S$，则 a_{ij}是 A_S的一个元素

由此：

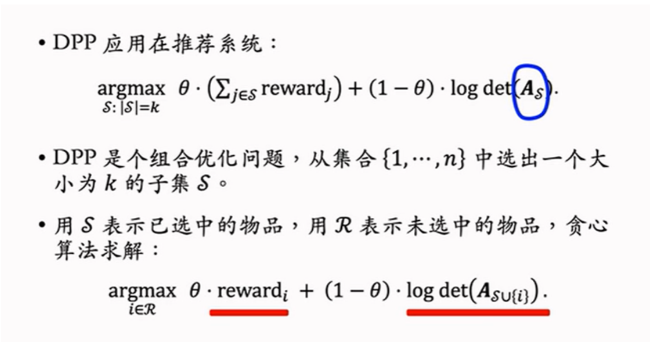

$A_{S\cup i}$在矩阵 A_S基础上多一行和一列，初始状态下S只有1个物品，A_S是1×1矩阵，我们希望红色下划线的两项都尽可能大

DPP的求解

暴力算法

对于单个i，计算 $A_{S\cup i}$的行列式需要 $O(|S|^3)$时间

对R中所有的i，计算行列式需要 $O(|S|^3\cdot|R|)$

需要重复上过程k次来选择k个物品，暴力计算行列式，总时间复杂度为 $O(|S|^3\cdot|R|\cdot k) = O(nk^4)$

因此暴力算法总时间复杂度为 $O(n^2d + nk^4)$，第一项是计算矩阵A的时间，第二项是计算行列式的时间，这个算法太慢

Hulu快速算法

Hulu仅需 $O(n^2d + nk^2)$的时间从n个物品中选出k个物品，它利用Cholesky分解来计算所有的行列式，仅需 nk^2

Cholesky分解：

（1）分解 $A_S = LL^T$，其中L是下三角矩阵（对角线以上元素全为0）

（2）Cholesky分解可用于计算 A_S的行列式

*性质：下三角矩阵L的行列式det(L)等于L对角线元素乘积

于是 $det(A_S) = det(L)^2 = \Pi_i l_{ii}^2$

（3）已知矩阵 $A_S = LL^T$，则可以快速求出所有 $A_{S\cup i}$的Cholesky分解（每轮循环增加一行和一列，求Cholesky分解的情况变化不大），因此可以快速算出所有$A_{S\cup i}$的行列式

DPP的扩展（改进)

用上述贪心算法的问题：随着集合S增大，其中相似物品越来越多，物品向量会趋近线性相关，导致行列式趋近为0，对数趋于负无穷，因而做出如下改进：

DPP结合滑动窗口

规则约束

实际推荐系统有很多规则约束，例如最多连续出5篇视频笔记（若已经连续出了5篇视频笔记，下一篇必须是图文笔记）

因此算法不能从R中选择任意物品，它必须按规则排除掉R中的部分物品，从而满足规则，得到求解公式：

• 用规则排除掉 $\mathcal{R}$ 中的部分物品，得到子集 $\mathcal{R}'$，然后求解：

$$\boxed{\underset{i \in \mathcal{R}'}{\operatorname{argmax}}}\ \theta \cdot \text{reward}_i + (1-\theta) \cdot \log\det\left(\boldsymbol{A}_{\mathcal{W} \cup \{i\}}\right).$$